

Caso de estudio: inferencia estadística de comunidades en una red S&P 500

LDS1121 - Redes complejas

Resumen

Este documento interpreta los resultados obtenidos al ajustar un modelo de bloques estocásticos corregido por grado a una red de relaciones proveedor/comprador entre empresas del S&P 500. La notación sigue el apunte *Metodos basados en inferencia estadística*: los grupos son $1, \dots, q$, la asignación latente es $g = (g_1, \dots, g_n)$, los parámetros de grado esperado son c_i , y la matriz de intensidades comunitarias es $\Omega = (\omega_{rs})$. El resultado principal es que el criterio penalizado selecciona $q = 3$ tanto en la red completa como en la minired. La partición no representa solo comunidades densas: separa un bloque asortativo de consumo/pagos/retail y una estructura tecnológica disasortativa, en la cual dos bloques se conectan intensamente entre sí.

1. Planteamiento del caso

La red original es dirigida: una arista $u \rightarrow v$ se interpreta como una relación proveedor $\rightarrow$ comprador. Para el ajuste del modelo se usa la proyección no dirigida G_1 , de modo que dos empresas quedan conectadas si existe al menos una relación en cualquier dirección. Si $A^\rightarrow$ denota la matriz dirigida, la matriz usada en la inferencia es

$$A_{ij} = \mathbf{1}\{A_{ij}^\rightarrow + A_{ji}^\rightarrow > 0\}.$$

Esta transformación conserva la existencia de relación económica, pero no su dirección. Por tanto, las comunidades inferidas no deben leerse como cadenas causales de suministro, sino como patrones estructurales de asociación.

Se analizan dos redes:

$$G_1 = (V, E), \quad G_{\text{mini}} = G_1[V_{\text{mini}}], \quad V_{\text{mini}} = \{i \in V : k_i \geq 2\}.$$

La red completa tiene 30 nodos, 37 aristas y dos componentes conexas de tamaños 11 y 19. La minired tiene 15 nodos, 22 aristas y dos componentes conexas de tamaños 7 y 8. Esta separación en componentes ya anticipa parte del resultado: el modelo no puede colocar aristas entre componentes desconectadas, por lo que la inferencia debe reflejar esa estructura.

2. Modelo y notación

Seguimos la notación del apunte. Sea A la matriz de adyacencia no dirigida, con entradas A_{ij} . El grado observado del nodo i es

$$k_i = \sum_j A_{ij}, \quad 2m = \sum_i k_i.$$

El modelo de bloques estocásticos corregido por grado divide los nodos en q grupos etiquetados por $1, \dots, q$. La etiqueta del nodo i es g_i . Condicionalmente a g , el modelo coloca aristas con media proporcional a

$$\omega_{g_i g_j} \frac{c_i c_j}{2m}.$$

Aquí c_i captura la propensión individual del nodo i a tener aristas, mientras que ω_{rs} captura la intensidad de conexión entre los grupos r y s .

Para una asignación fija g , definimos

$$\kappa_r = \sum_i \delta_{g_i r} c_i, \quad m_{rs} = \sum_{ij} \delta_{g_i r} \delta_{g_j s} A_{ij}.$$

La cantidad κ_r mide el volumen de grado esperado del grupo r , y m_{rs} mide la masa observada de aristas entre los grupos r y s . En redes no dirigidas, esta convención cuenta dos veces la masa total, de modo que

$$\sum_{r,s} m_{rs} = 2m.$$

Al maximizar la log-verosimilitud con respecto a los parámetros continuos, se obtienen los estimadores

$$\hat{c}_i = k_i, \quad \hat{\omega}_{rs} = \frac{2m m_{rs}}{\kappa_r \kappa_s}.$$

Sustituyendo estos estimadores se obtiene la log-verosimilitud perfilada

$$L(g) = \frac{1}{2} \sum_{r,s} m_{rs} \log \left(\frac{m_{rs}}{\kappa_r \kappa_s} \right) + \text{constantes}.$$

El problema de detección de comunidades es entonces

$$\hat{g}_q = \arg \max_{g: V \rightarrow \{1, \dots, q\}} L(g).$$

2.1. Como se interpreta $\hat{\omega}_{rs}$

La fórmula

$$\hat{\omega}_{rs} = \frac{2m m_{rs}}{\kappa_r \kappa_s}$$

es el centro interpretativo del caso. Si dos grupos tienen mucho volumen de grado, entonces $\kappa_r \kappa_s$ es grande y el modelo espera cierta cantidad de aristas entre ellos aun sin estructura especial. Por eso $\hat{\omega}_{rs}$ no mide solamente cuantas aristas hay; mide cuantas hay *en relación con lo que se esperaría por grado*.

Una diagonal grande, $\hat{\omega}_{rr}$, indica estructura asortativa: los nodos del grupo r se conectan entre si mas de lo esperado. Una entrada fuera de la diagonal grande, $\hat{\omega}_{rs}$ con $r \neq s$, indica estructura disasortativa o de roles: los nodos de r se conectan preferentemente con los de s .

3. Selección del número de grupos

Para cada valor de q se maximizo $L(g)$ mediante búsqueda greedy con múltiples arranques. Como $L(g)$ tiende a mejorar al aumentar q , se uso también una penalización tipo BIC:

$$\text{BIC}_{\text{like}}(q) = -2\hat{L}_q + p_q \log(2m), \quad p_q \approx \frac{q(q+1)}{2} - q.$$

El menor valor del criterio penalizado se obtuvo en $q = 3$ para ambas redes.

Cuadro 1: Barrido de q para la red completa y la minired. Menor BIC-like es mejor.

Red	q	L perfilada	BIC-like	Modularidad diagnostica
G_1	2	-135.264	274.832	0.456
G_1	3	-118.629	250.169	0.018
G_1	4	-112.527	250.878	-0.245
G_1	5	-110.734	264.508	-0.043
G_{mini}	2	-68.369	140.521	0.483
G_{mini}	3	-59.358	130.068	0.067
G_{mini}	4	-55.677	134.059	-0.214
G_{mini}	5	-54.519	146.879	-0.143

La modularidad es alta para $q = 2$, pero no es el criterio que se esta optimizando. Esto no es una contradiccion: la modularidad favorece particiones asortativas, mientras que el DC-SBM puede detectar estructuras disasortativas. En este caso, $q = 3$ permite separar una comunidad cerrada de consumo/pagos y, al mismo tiempo, dividir la parte tecnologica en dos roles complementarios.




Figura 1: Barrido de q para G_1 . El criterio penalizado selecciona $q = 3$.




Figura 2: Barrido de q para G_{mini} . La minired conserva la misma escala estructural: $q = 3$.

4. Resultados en la red completa

En esta seccion usamos grupos 1, 2, 3. La correspondencia con el notebook es:

$$C0 \equiv 1, \quad C1 \equiv 2, \quad C2 \equiv 3.$$

La particion estimada en G_1 es:

Cuadro 2: Comunidades estimadas en G_1 .

Grupo	Lectura	Nodos	Aristas internas	κ_r	Miembros principales
1	Consumo, pagos y retail	11	13	26	AAPL, AVGO, BAC, BRK.B, COST, HD, JPM, MA, PG, V, WMT
2	Infraestructura/IA y periferia conectada a plataformas	11	0	24	ABBV, AMD, CVX, GE, JNJ, LLY, NFLX, NVDA, PLTR, UNH, XOM
3	Plataformas y compradores tecnologicos	8	0	24	AMZN, GOOG, GOOGL, META, MSFT, MU, ORCL, TSLA

Las matrices agregadas por bloques fueron

$$M = \begin{pmatrix} 26 & 0 & 0 \\ 0 & 0 & 24 \\ 0 & 24 & 0 \end{pmatrix}, \quad \hat{\Omega} = \begin{pmatrix} 2.846 & 0 & 0 \\ 0 & 0 & 3.083 \\ 0 & 3.083 & 0 \end{pmatrix}.$$

4.1. Por que aparece un bloque cerrado de consumo/pagos

El grupo 1 tiene $\kappa_1 = 26$ y toda su masa observada queda en la diagonal: $m_{11} = 26$. Como la red completa tiene $m = 37$, entonces $2m = 74$ y

$$\hat{\omega}_{11} = \frac{74 \cdot 26}{26^2} = \frac{74}{26} = 2.846.$$

Este valor alto significa que el bloque de consumo/pagos tiene mas conexion interna de la esperada bajo un modelo que solo respeta grados. Sustantivamente, esto refleja un subecosistema alrededor de ‘AAPL’, pagos (‘MA’, ‘V’), retail (‘WMT’, ‘COST’, ‘HD’) y nodos financieros asociados (‘BAC’, ‘JPM’, ‘BRK.B’).

El hecho de que $m_{12} = m_{13} = 0$ tambien es informativo. No solo se detecta una comunidad densa; se detecta una componente desconectada del bloque tecnologico. Por eso el grupo 1 aparece como una comunidad asortativa limpia.

4.2. Por que la parte tecnologica se parte en dos roles

Los grupos 2 y 3 tienen $\kappa_2 = \kappa_3 = 24$, pero no tienen aristas internas:

$$m_{22} = m_{33} = 0.$$

Toda su masa va de un grupo al otro:

$$m_{23} = m_{32} = 24.$$

Por tanto,

$$\hat{\omega}_{23} = \frac{74 \cdot 24}{24 \cdot 24} = \frac{74}{24} = 3.083.$$

Esta es la intensidad mas grande en G_1 . Matematicamente, el modelo prefiere separar esta componente en dos bloques porque si se colocaran todos estos nodos en un solo grupo, el modelo describiria la region tecnologica como una comunidad densa. Pero los datos no tienen muchas aristas dentro de cada lado; tienen aristas cruzadas. La particion en dos roles aumenta la verosimilitud porque concentra masa en m_{23} y m_{32} , y evita asignar probabilidad a diagonales que en realidad son cero.

La interpretacion economica es natural: un lado contiene nodos de infraestructura, semiconductores, IA y periferia conectada a plataformas ('NVIDA', 'AMD', 'PLTR' y empresas conectadas a 'AMZN' o 'MSFT'); el otro contiene plataformas o compradores tecnologicos ('AMZN', 'MSFT', 'ORCL', 'GOOGL', 'TSLA'). La red no dice que todos los nodos tecnologicos sean parecidos; dice que hay una relacion de complementariedad entre dos lados.




Figura 3: Radiografía de bloques para G_1 . La diagonal del grupo 1 muestra estructura asortativa; la masa entre los grupos 2 y 3 muestra estructura disasortativa.




Figura 4: Vista focal del cruce dominante en G_1 . El par de bloques 2–3 concentra la intensidad corregida mas alta.

5. Resultados en la minired

La minired elimina nodos de grado 1 y conserva el nucleo relacional. La correspondencia de etiquetas vuelve a ser:

$$C0 \equiv 1, \quad C1 \equiv 2, \quad C2 \equiv 3.$$

La particion resultante fue:

Cuadro 3: Comunidades estimadas en G_{mini} .

Grupo	Lectura	Nodos	Aristas internas	κ_r	Miembros
1	Nucleo pagos/retail	7	9	18	AAPL, BAC, COST, HD, MA, V, WMT
2	Plataformas tecnologicas	5	0	13	AMZN, GOOGL, MSFT, ORCL, TSLA
3	Infraestructura/IA	3	0	13	AMD, NVDA, PLTR

Las matrices fueron

$$M = \begin{pmatrix} 18 & 0 & 0 \\ 0 & 0 & 13 \\ 0 & 13 & 0 \end{pmatrix}, \quad \hat{\Omega} = \begin{pmatrix} 2.444 & 0 & 0 \\ 0 & 0 & 3.385 \\ 0 & 3.385 & 0 \end{pmatrix}.$$

Ahora $m = 22$, por lo que $2m = 44$. Para el bloque de pagos/retail,

$$\hat{\omega}_{11} = \frac{44 \cdot 18}{18^2} = \frac{44}{18} = 2.444.$$

Para el cruce tecnologico,

$$\hat{\omega}_{23} = \frac{44 \cdot 13}{13 \cdot 13} = \frac{44}{13} = 3.385.$$

La intensidad cruzada aumenta al pasar a la minired. Esto ocurre porque se retiraron nodos hoja que aportaban contexto periférico, y quedo una estructura mas pura: plataformas tecnologicas en un lado e infraestructura/IA en el otro. La conclusion no cambia; se vuelve mas nitida.




Figura 5: Radiografía de bloques para G_{mini} . La estructura tecnologica disasortativa se vuelve mas clara al eliminar nodos hoja.




Figura 6: Vista focal del cruce dominante en G_{mini} . La relacion entre plataformas e infraestructura/IA concentra la mayor intensidad corregida.

6. Lectura visual de las particiones

Las figuras de adyacencia ordenada y red partida son utiles porque traducen las matrices M y $\hat{\Omega}$ a patrones visuales.




Figura 7: Matriz de adyacencia de G_1 antes y después de ordenar por comunidades. La ordenación revela un bloque diagonal para consumo/pagos y dos rectángulos fuera de la diagonal para la parte tecnológica.




Figura 8: Diagnóstico final de G_1 : matriz de adyacencia ordenada y red partida por comunidades.

El patrón visual confirma la interpretación matemática:

- El grupo 1 tiene un bloque diagonal, por lo que es asortativo.
- Los grupos 2 y 3 no tienen bloques diagonales relevantes; sus aristas aparecen fuera de la diagonal.
- La baja modularidad diagnóstica para $q = 3$ no invalida la partición: simplemente indica que la estructura no es puramente modular/asortativa.

7. Explicacion matematica de por que ocurre

El mecanismo puede verse directamente en la log-verosimilitud perfilada:

$$L(g) = \frac{1}{2} \sum_{r,s} m_{rs} \log \left(\frac{m_{rs}}{\kappa_r \kappa_s} \right) + \text{constantes.}$$

Para una particion dada, los pares (r, s) con $m_{rs} = 0$ no aportan al sumatorio. Por tanto, el modelo recompensa particiones que concentran la masa observada en pocos pares de bloques, siempre que esa concentracion sea grande en relacion con $\kappa_r \kappa_s$.

En G_1 se observan dos concentraciones extremas:

$$m_{11} = 26, \quad m_{23} = m_{32} = 24,$$

y los demas pares son cero. Esto genera una matriz $\hat{\Omega}$ con solo dos intensidades positivas relevantes. La primera, $\hat{\omega}_{11}$, explica la comunidad cerrada de consumo/pagos. La segunda, $\hat{\omega}_{23}$, explica la estructura de roles tecnologicos.

La correccion por grado es crucial. ‘NVDA’, ‘AMZN’ y ‘MSFT’ tienen grados altos, pero el modelo no los agrupa solamente por ser nodos centrales. Primero fija

$$\hat{c}_i = k_i.$$

Despues pregunta si, dadas esas propensiones individuales, las aristas caen preferentemente dentro de algun grupo o entre ciertos grupos. La respuesta es:

1. En consumo/pagos, las aristas caen dentro del mismo grupo.
2. En tecnologia, las aristas caen entre dos grupos distintos.

Por eso el resultado sustantivo no es “hay tres comunidades densas”. El resultado correcto es:

una comunidad asortativa + dos roles tecnologicos disasortativos.

8. Conclusion

El DC-SBM muestra que la red no tiene una unica forma de organizacion. Una parte se comporta como comunidad tradicional: el bloque de pagos, retail y consumo tiene conexiones internas y queda separado de la componente tecnologica. Otra parte se comporta como estructura de roles: los nodos tecnologicos se dividen en dos lados con muchas aristas cruzadas y sin aristas internas dentro de cada lado.

La minired confirma esta lectura. Al eliminar nodos de grado 1, el bloque de consumo/pagos permanece y el cruce plataformas–infraestructura/IA se vuelve aun mas intenso en terminos de $\hat{\omega}_{rs}$. Por tanto, el valor $q = 3$ no es solo una decision numerica del BIC-like; corresponde a una interpretacion estructural clara:

pagos/retail $\oplus$ plataformas tecnologicas $\leftrightarrow$ infraestructura/IA.
--